PRÁCTICA FINAL

Análisis y Modelado de Datos

Estadística para Data Science

Campo	Detalle
Asignatura	Estadística para Data Science
Módulo	Módulo de Estadística
Formato	Práctica individual
Entrega	GitHub Classroom — enlace proporcionado por el docente
Calificación máx.	10 puntos

IMPORTANTE

La entrega se realiza exclusivamente a través de GitHub y Google Classroom. No se aceptan entregas por correo, aula virtual ni en ningún formato comprimido (.zip, .rar, etc.). El proyecto debe estar únicamente en la rama principal del repositorio. será la única Rama evaluable.

El repositorio debe ser accesible para el docente antes de la fecha límite. Cualquier commit realizado después de esa fecha no será tenido en cuenta.

El plagio o la copia entre grupos supone un 0 automático para todos los implicados y se notificará al departamento.

0. Normas Generales

0.1 Lenguaje y entorno

- Todo el código debe estar escrito en Python 3.12 o superior.
- Se permite el uso de las siguientes librerías: NumPy, Pandas, Matplotlib, Seaborn, Scikit-Learn, SciPy y Statsmodels.
- No se permite el uso de AutoML, LLMs o herramientas de generación automática de código para resolver los ejercicios.
- Cada script debe poder ejecutarse de forma autónoma desde la raíz del proyecto con:

```
python ejercicioX_nombre.py
```

0.2 Entrega mediante GitHub y Classroom

La entrega se realiza a través del enlace de GitHub y Classroom proporcionado por el docente. Al aceptar la tarea se creará automáticamente un repositorio privado donde deberás subir todo el trabajo.

> **IMPORTANTE**
> No se aceptan entregas en formato .zip, .rar ni ningún otro archivo comprimido bajo ningún concepto.
> El repositorio debe contener exactamente la estructura de carpetas indicada a continuación.
> El último commit antes de la fecha límite es el que se evaluará.

El repositorio debe tener exactamente la siguiente estructura:

```
practica_final_[apellido1_apellido2_nombre]/
├── ejercicio1_descriptivo.py
├── ejercicio2_inferencia.py
├── ejercicio3_regresion_multiple.py
├── ejercicio4_series_temporales.py
├── Respuestas.md
└── data/
    ├── <dataset> . csv/ .parquet
└── output/
    ├── ej1_*.png / .csv
    ├── ej2_*.png / .txt
    ├── ej3_*.png / .txt
    └── ej4_*.png / .txt
```

0.3 Reproducibilidad

- Cualquier generación de números aleatorios debe fijar la semilla con `np.random.seed(42)` o `random_state=42`.
- Los resultados deben ser idénticos en cada ejecución sobre el mismo entorno.
- Si el código tarda más de 5 minutos en ejecutarse en un ordenador estándar, optimizarlo o justificarlo en el Respuestas.md.

0.4 Calidad del código

- Cada función debe tener una docstring con: descripción, parámetros y valor de retorno.

- El código debe estar comentado en las secciones no triviales.
- Se valorará la claridad, la modularidad y el uso de funciones reutilizables.

Ejercicio 1 — Análisis Estadístico Descriptivo [2,5 pts]

En este primer ejercicio realizarás un análisis estadístico descriptivo completo sobre un dataset de tu elección. El objetivo es que seas capaz de **caracterizar los datos antes de modelarlos**, identificando su estructura, calidad y las relaciones entre variables.

1.1 Selección del dataset

El dataset debe cumplir todos los requisitos siguientes:

- **Tamaño:** mínimo 8 campos (columnas) y peso máximo de 15 MB.
- **Tipos de variables:** debe contener al menos 2 campos categóricos y al menos 3 campos numéricos continuos.
- **Variable objetivo (target):** debe existir un campo numérico continuo sobre el que tenga sentido hacer regresión. Declara explícitamente cuál es en el fichero Respuestas.md.
- **Fuente:** dataset público y citable (Kaggle, UCI ML Repository, datos.gob.es, Our World in Data, etc.).
- **Prohibiciones:** no se puede usar el dataset Titanic, Iris, Boston Housing ni ningún dataset de ejemplo de Scikit-Learn para este ejercicio.

Datasets recomendados (no obligatorios)

- Kaggle: House Prices – Advanced Regression Techniques
- Kaggle: NYC Airbnb Open Data
- UCI ML Repository: Student Performance Dataset
- Datos Abiertos España: datos.gob.es (cualquier dataset con variables continuas)
- Our World in Data: owid.io (indicadores socioeconómicos por país y año)

1.2 Requisitos del análisis descriptivo

El análisis debe incluir obligatoriamente los siguientes apartados. Cada uno debe ir acompañado de una interpretación escrita en

Respuestas.md.

A) Resumen estructural

- Número de filas, columnas y tamaño en memoria.
- Tipos de dato de cada columna (dtypes).
- Porcentaje de valores nulos por columna y decisión de tratamiento.

B) Estadísticos descriptivos de variables numéricas

- Media, mediana, moda, desviación típica, varianza, mínimo, máximo y cuartiles.
- Rango intercuartílico (IQR) de la variable objetivo.
- Coeficiente de asimetría (skewness) y curtosis para al menos la variable objetivo.

C) Distribuciones

- Histogramas de todas las variables numéricas
- Boxplots de la variable objetivo, segmentados por cada variable categórica.
- Detección y tratamiento de outliers (método IQR o Z-score; justifica cuál usas).

D) Variables categóricas

- Frecuencia absoluta y relativa de cada categoría.
- Gráfico de barras o de sectores para cada variable categórica.
- Análisis de si alguna categoría domina el dataset (desbalance).

E) Correlaciones

- Mapa de calor (heatmap) de la matriz de correlaciones de Pearson de las variables numéricas.
- Identificación de las tres variables con mayor correlación (en valor absoluto) con la variable objetivo.
- Detección de posible multicolinealidad entre predictoras (pares con |r| > 0,9).

1.3 Salidas requeridas en output/

Fichero	Contenido
ej1_descriptivo.csv	Tabla de estadísticos descriptivos de todas las variables numéricas (pandas describe)
ej1_histogramas.png	Histogramas
ej1_boxplots.png	Boxplots de la variable objetivo por cada variable categórica
ej1_heatmap_correlacion.png	Mapa de calor de la matriz de correlaciones
ej1_categoricas.png	Gráficos de frecuencia de las variables categóricas

Ejercicio 2 — Inferencia con Scikit-Learn [2,5 pts]

Usando el mismo dataset del Ejercicio 1, entrena y evalúa un modelo de aprendizaje automático supervisado para predecir la variable objetivo. El objetivo es que comprendas tanto la mecánica de los algoritmos como la **interpretación crítica de sus resultados**.

2.1 Preprocesamiento

- Aplica las transformaciones necesarias: codificación de variables categóricas (LabelEncoder, OneHotEncoder o get_dummies), escalado si procede (StandardScaler o MinMaxScaler) y eliminación de columnas que no aporten información.
- Divide los datos en Train (80 %) y Test (20 %) usando `train_test_split(..., random_state=42)`.
- El preprocesamiento debe estar documentado y justificado en Respuestas.md.

2.2 Modelo A — Regresión Lineal (LinearRegression)

- Entrena el modelo con los datos de entrenamiento.
- Evalúa sobre el test set calculando: MAE, RMSE y R^2.
- Genera el gráfico de residuos (valores predichos en X, residuos en Y).
- Comenta los resultados en Respuestas.md: ¿el modelo es bueno?, ¿hay overfitting o underfitting?, ¿qué variables son más influyentes?

2.3 Conclusiones

- Dedica un apartado de Respuestas.md a extraer conclusiones sobre qué información del Ejercicio 1 resultó más útil para interpretar los resultados.

2.4 Salidas requeridas en output/

Fichero	Contenido
ej2_metricas_regresion.txt	MAE, RMSE y R^2 de la regresión lineal
ej2_residuos.png	Gráfico de residuos del modelo de regresión lineal

Ejercicio 3 — Regresión Lineal Múltiple en NumPy [2,5 pts]

En clase vimos la regresión lineal simple. Ahora implementarás **desde cero con NumPy** la versión múltiple, usando la solución analítica de Mínimos Cuadrados Ordinarios (OLS):

$$\beta = (X^T X)^{-1} X^T y$$

No se permite usar Scikit-Learn ni ninguna otra librería de machine learning para el ajuste del modelo. Solo NumPy.

¿Para qué sirve este ejercicio?

Entender el funcionamiento interno de la regresión lineal desmitifica la caja negra de sklearn.

La formulación matricial es la base de muchos otros modelos: Ridge, Lasso, PCR, etc.

Programar el gradiente o la solución directa desarrolla la intuición matemática necesaria para el máster.

3.1 Archivo de partida

Se te proporciona el fichero **ejercicio3_regresion_multiple.py** con la cabecera de las funciones ya definida y un `main` que genera datos sintéticos con semilla fija para que puedas validar tu implementación.

3.2 Funciones que debes implementar

1. **regresion_lineal_multiple(X_train, y_train, X_test)** — Calcula los coeficientes β y devuelve las predicciones sobre X_test.
2. **calcular_mae(y_real, y_pred)** — Mean Absolute Error.
3. **calcular_rmse(y_real, y_pred)** — Root Mean Squared Error.
4. **calcular_r2(y_real, y_pred)** — Coeficiente de determinación R^2.
5. **graficar_real_vs_predicho(y_real, y_pred)** — Scatter plot Real vs. Predicho con la línea de referencia perfecta.

3.3 Valores de referencia del profesor

Con los datos sintéticos generados en el `main` (semilla = 42), tu implementación debería producir resultados próximos a:

Parámetro / Métrica	Valor de referencia (aprox.)
β_0 (intercepto)	≈ 5.0
β_1	≈ 2.0
β_2	≈ −1.0
β_3	≈ 0.5
MAE (test set)	≈ 1.20 (±0.20)
RMSE (test set)	≈ 1.50 (±0.20)
R^2 (test set)	≈ 0.80 (±0.05)

3.4 Salidas requeridas en output/

Fichero	Contenido
ej3_coeficientes.txt	Coeficientes ajustados vs. coeficientes reales del main
ej3_metricas.txt	MAE, RMSE y R^2 sobre el test set sintético
ej3_predicciones.png	Scatter plot de Valores Reales vs. Valores Predichos

Ejercicio 4 — Análisis de Series Temporales [2,5 pts]

En este ejercicio trabajarás con una **serie temporal sintética generada por el fichero ejercicio4_series_temporales.py** (semilla = 42). La serie cubre 6 años de datos diarios y contiene componentes conocidos que debes identificar y analizar.

> **IMPORTANTE**
> NO debes modificar la función generar_serie_temporal() ni la semilla.
> Todos tus análisis deben realizarse sobre la serie que genera esa función, no sobre datos externos.

4.1 Archivo de partida

Se te proporciona el fichero **ejercicio4_series_temporales.py** con la serie ya generada y las cabeceras de las funciones que debes implementar.

4.2 Tareas a realizar

6. **Visualización:** genera un gráfico de la serie completa con título, etiquetas de ejes y cuadrícula.
7. **Descomposición:** aplica `seasonal_decompose(model='additive', period=365)` y guarda los 4 subgráficos.
8. **Análisis del residuo:**
   – Calcula estadísticos descriptivos del residuo (media, std, asimetría, curtosis).
   – Aplica el test ADF para verificar si el residuo es estacionario.
   – Genera el gráfico ACF y PACF del residuo.
   – Genera el histograma del residuo con la curva normal teórica superpuesta.

4.3 Preguntas que debes responder en Respuestas.md

- ¿La serie presenta tendencia? ¿De qué tipo?
- ¿Hay estacionalidad? ¿Cuál es el periodo aproximado y la amplitud?
- ¿Se aprecian ciclos de largo plazo? ¿Cómo los distingues de la tendencia?
- ¿Hay ruido? ¿Cuánto (en términos de desviación típica del residuo)?
- ¿El ruido se ajusta a un ruido ideal (gaussiano, media ≈ 0, sin autocorrelación)? Justifica con los resultados de los tests.

4.4 Salidas requeridas en output/

Fichero	Contenido
ej4_serie_original.png	Gráfico de la serie completa
ej4_descomposicion.png	Los 4 subgráficos de la descomposición
ej4_acf_pacf.png	ACF y PACF del componente residuo

ej4_histograma_ruido.png	Histograma del residuo con curva normal

Rúbrica de Evaluación

Distribución de puntos

Ejercicio	Criterio	Peso
Ejercicio 1	Análisis Estadístico Descriptivo	2,5 pts
Ejercicio 2	Inferencia con Scikit-Learn	2,5 pts
Ejercicio 3	Regresión Lineal Múltiple en NumPy	2,5 pts
Ejercicio 4	Análisis de Series Temporales	2,5 pts
TOTAL		10 pts

Rúbrica detallada por ejercicio

Ejercicio 1 — Análisis Estadístico Descriptivo (2,5 pts)

Criterio	Excelente (100 %)	Suficiente (60 %)	Insuficiente (0 %)
Dataset válido(0,5 pts)	Cumple todos los requisitos (8+ cols, <15 MB, categóricas, target continuo). Fuente citada.	Cumple la mayoría de requisitos. Algún dato menor incorrecto.	No cumple los requisitos básicos (pocas columnas, sin target claro, etc.).
Estadísticos descriptivos(0,6 pts)	Media, mediana, std, IQR, asimetría y curtosis correctos y comentados con profundidad.	Estadísticos básicos correctos. Poca profundidad en los comentarios.	Estadísticos incorrectos o ausentes.
Distribuciones y outliers(0,6 pts)	Histogramas con KDE, boxplots por categoría. Outliers detectados, tratados y justificados.	Gráficos presentes. Outliers detectados pero sin justificación del tratamiento.	Gráficos ausentes o incorrectos. Outliers ignorados.
Variables categóricas(0,5 pts)	Frecuencias, gráficos y análisis de desbalance completos.	Frecuencias y gráficos presentes. Sin análisis de desbalance.	Análisis ausente o incorrecto.
Correlaciones(0,3 pts)	Heatmap correcto. Top-3 correlaciones identificadas. Multicolinealidad analizada.	Heatmap presente. Correlaciones identificadas sin análisis de multicolinealidad.	Heatmap ausente o interpretación incorrecta.

Ejercicio 2 — Inferencia con Scikit-Learn (2,5 pts)

Criterio	Excelente (100 %)	Suficiente (60 %)	Insuficiente (0 %)
Preprocesamiento(0,4 pts)	Codificación, escalado y split correctos y justificados.	Preprocesamiento básico correcto. Sin justificación.	Preprocesamiento incorrecto o ausente.
Regresión Lineal(1,6 pts)	MAE, RMSE y R^2 correctos. Gráfico de coeficientes y residuos. Análisis crítico completo.	Métricas correctas. Gráficos presentes. Análisis superficial.	Métricas incorrectas o ausentes. Sin análisis.

Comparativa(0,5 pts)	Comparativa clara y conectada con el Ejercicio 1. Propone mejoras concretas.	Comparativa presente pero sin conexión con el análisis descriptivo.	Sin comparativa.

Ejercicio 3 — Regresión Lineal Múltiple en NumPy (2,5 pts)

Criterio	Excelente (100 %)	Suficiente (60 %)	Insuficiente (0 %)
Implementación OLS(1,2 pts)	Función correcta: columna de unos, producto matricial, resolución del sistema. Sin sklearn.	Función parcialmente correcta. Errores menores en la implementación.	Función incorrecta, usa sklearn o no implementada.
Métricas NumPy(0,6 pts)	MAE, RMSE y R^2 implementados correctamente sin sklearn.	Métricas correctas pero algún error menor.	Métricas incorrectas o usando sklearn.
Resultados y análisis(0,4 pts)	Coeficientes ajustados próximos a los de referencia (±0,2). Gráfico Real vs. Predicho claro.	Coeficientes con desviación mayor a la esperada. Gráfico presente.	Resultados muy alejados de la referencia o sin gráfico.
Calidad del código(0,3 pts)	Docstrings completas, código comentado, modular y legible.	Código funcional pero con poca documentación.	Código ilegible o sin documentación.

Ejercicio 4 — Análisis de Series Temporales (2,5 pts)

Criterio	Excelente (100 %)	Suficiente (60 %)	Insuficiente (0 %)
Descomposición(0,7 pts)	Descomposición correcta con period=365. Gráfico limpio y etiquetado.	Descomposición presente. Parámetros subóptimos o gráfico sin etiquetar.	Descomposición ausente o incorrecta.
Análisis tendencia y estacionalidad(0,8 pts)	Identifica correctamente la tendencia lineal y la estacionalidad anual. Justificación con gráficos y ACF.	Componentes identificados sin justificación cuantitativa.	Componentes no identificados o identificados incorrectamente.
Análisis del ruido(1 pts)	Estadísticos, test de normalidad (p-value), ADF Test e histograma con curva normal. Conclusión razonada sobre si es ruido ideal.	Estadísticos básicos y test aplicados. Conclusión superficial.	Análisis del ruido ausente o sin tests estadísticos.

Penalizaciones

Las penalizaciones se aplican sobre la nota final obtenida y son acumulativas. La nota mínima tras penalizaciones es 0.

Infraccion	Penalizacion
Entrega fuera de GitHub y Classroom (cualquier otro formato o canal)	−2,0 pt (o no evaluado si no es accesible)
Entrega con más de 1 día de retraso	−10 % por día
Estructura de carpetas incorrecta en el repositorio	−0,5 pts
Faltan ficheros de salida en output/ (por cada fichero que falta)	−0,2 pts por fichero
El código no se ejecuta sin errores en un entorno limpio	−0,5 pts por ejercicio afectado
Semilla aleatoria no fijada en ejercicios que la requieren	−0,3 pts
Uso de sklearn para el ajuste del modelo en el Ejercicio 3	−1,0 pt (anula la parte de implementación)
Respuestas.md incompleto (por pregunta no respondida)	−0,15 pts por pregunta. Mínimo 50% de las preguntas completadas. fichero vacío -2 pts.
Código sin docstrings ni comentarios en funciones propias	Hasta -0.5pt
Plagio total o parcial entre entregas	0 en la práctica completa

Checklist de Entrega

Antes de subir tu entrega, comprueba que has completado todos los puntos de esta lista:

Repositorio GitHub Classroom

- El repositorio ha sido creado a través del enlace de GitHub Classroom del docente
- La estructura de carpetas del repositorio es exactamente la indicada en la sección 0.2
- La carpeta output/ contiene todos los ficheros requeridos
- El ultimo commit esta realizado antes de la fecha límite

Ejercicio 1

- El dataset cumple todos los requisitos (tamaño, tipos, target)
- Todos los gráficos están guardados en output/ con los nombres correctos
- ej1_descriptivo.csv contiene los estadísticos de todas las variables numéricas
- Los outliers están documentados en ej1_outliers.txt

Ejercicio 2

- El preprocesamiento (codificación, escalado) está aplicado y justificado
- Las métricas de regresión lineal están en ej2_metricas_regresion.txt
- La transformación del target para logística está documentada en Respuestas.md
- La matriz de confusión está guardada como ej2_matriz_confusion.png

Ejercicio 3

- La función regresion_lineal_multiple() está implementada sin sklearn
- Las funciones calcular_mae, calcular_rmse y calcular_r2 están implementadas
- El main se ejecuta sin errores y produce los ficheros de output
- Los coeficientes ajustados son próximos a los valores de referencia

Ejercicio 4

- generar_serie_temporal() no ha sido modificada
- Los 5 ficheros de output están generados
- El test ADF y el test de normalidad están aplicados y sus resultados en ej4_analisis.txt

Respuestas.md

- Todas las preguntas del fichero Respuestas.md estan respondidas
- Las respuestas estan justificadas con valores numéricos de los analisis

¡Mucho ánimo y a disfrutar del análisis de datos!